
Zetteldatenbank

Projektbericht

Autor Jan Raring
Datum 04. June 2026
Version v1.0

Contents

Projektbeschreibung	3
Ausgangslage	3
Projektziel und Lösungsansatz	3
Ergebnis und Limitierungen	3
Verwendete Technologien	4
Die Datenbank	5
classes	5
classifications	6
classifiers	6
kreise	7
landschaften	7
ocr_results	7
orte	8
scans	8
sources	8
zettel	9

Projektbeschreibung

Ausgangslage

Das Westfälische Wörterbuch (WWb) ist auf Grundlage eines umfangreichen Zettelarchivs entstanden. Das Archiv besteht aus ca. 1,35 Millionen Karteikarten (im Folgenden meist *Zettel* genannt), die sich auf ein lautschriftliches Archiv (ca. 100.000 Zettel) und das eigentliche Belegarchiv (ca. 1,25 Millionen Zettel) aufteilen. Letzteres lässt sich in weitere Kategorien und Untersammlungen unterteilen. Eine genauere Erklärung hierüber liefert der zum WWb erschienene Beiband. Die vier wichtigsten Oberkategorien sind demnach die folgenden:

1. Kopien von Belegen aus dem lautschriftlichen Archiv,
2. Fragebogenabschrift,
3. Exzerpt aus schriftlichen Quellen,
4. Wortschatzsammlungen freiwilliger Mitarbeiter.

Viele Zettel sind mit einem Belegort versehen. Im Beiband und in der digitalen Fassung des WWb ist eine vollständige Liste aller Ortskürzel enthalten (siehe *Landschaften — Kreise — Orte*). Ebenfalls im Beiband enthalten ist eine Aufschlüsselung der Fragebogen nach Serie, eine Liste der schriftlichen Quellen sowie eine Liste der wichtigsten freiwilligen Mitarbeiter (siehe *Einführung: Zur Herkunft des Materials* sowie *Quellen und Schrifttum*).

Projektziel und Lösungsansatz

In einem ersten Schritt der Digitalisierung sind die Zettel beider Archive vorder- und rückseitig eingescannt worden. Das Ziel des aktuellen Projektes bestand darin, den nächsten Schritt zur digitalen Aufbereitung dieses Datenschatzes zu gehen. Es galt, den Bestand in eine Datenbank zu überführen und soweit möglich für jeden Zettel die folgenden Metadaten zu erschließen:

1. zu welcher Oberkategorie der Zettel gehört,
2. zu welchem Ort der Zettel gehört,
3. für Fragebogen: zu welcher Serie der Fragebogen gehört,
4. für schriftliche Quellen: aus welcher Quelle der Beleg stammt.

Die Erschließung ebendieser Metadaten bildete die Hauptarbeit. Es sind hierzu zwei Ansätze verfolgt worden. Zum einen wurde automatische Zeichenerkennung (OCR) verwendet um das Zettelarchiv durchsuchbar zu machen. Wie zu erwarten war, reichte die Qualität der OCR alleine nicht aus, um eine Klassifizierung durchzuführen. Gerade bei handschriftlichen Notizen und insbesondere bei solchen, die in Sütterlin verfasst worden sind, stößt diese Technik an ihre Grenzen. Dennoch boten die Resultate eine hervorragende Grundlage, um im nächsten Schritt eine Sammlung manuell gelabelter Zettel aufzubauen. Diese wiederum dienten als Grundlage für das Training künstlicher neuronaler Netze zur Bilderkennung. Das ganze war ein iterativer Prozess, sodass die Qualität der automatischen Klassifizierungen nach und nach verbessert werden konnten.

Ergebnis und Limitierungen

Das finale Modell ist mit 25.000 handgelabelten Zetteln trainiert worden, die sich auf 581 Klassen aufteilen. Auf einem Testdatensatz erreichte es eine Genauigkeit von ca. 93%. In der Praxis fällt

die Genauigkeit etwas geringer aus, da ein gewisser Teil des Archives noch als *out of distribution* anzusehen ist, d.h. einige Zettel gehören zu gar keiner der 581 im Training angesetzten Klassen. Am Ende ist das Modell auf alle 1.250.000 Zettel des Hauptarchivs angewandt und die Vorhersagen zusammen mit dem zugehörigen Maß an Vertrauenswürdigkeit (*confidence*) in einer Datenbank gespeichert worden. Einen weiteren Zugang zu den Daten bieten die zuvor erzeugten OCR-Ergebnisse und ein Satz auf diesen Ergebnissen beruhender Klassifizierungen nach Ort.

Die genaue Struktur der Datenbank und noch weitere Details zu den Daten selber sind dem nachfolgenden Kapitel zu entnehmen.

Der für das Projekt entwickelte Quellcode ist unter github.com/janraring/Zettelsortierung veröffentlicht worden. Es muss jedoch betont werden, dass dies kein Teil des eigentlichen Projektergebnisses ist und daher keine Gewährleistung hierfür übernommen wird. Der Quellcode möge vor allem denjenigen nützen, die in Zukunft mit der Datenbank an sich oder mit den Archivdaten allgemein zu tun haben.

Verwendete Technologien

- Zur Programmierung wurde Python 3.12 verwendet.
- Zur automatische Zeichenerkennung ist die Bilderkennungs-Bibliothek *OpenCV* und ein künstliches Neuronales Netz aus der *PaddleOCRv5*-Familie zum Einsatz gekommen.
- Die Modelle zur automatischen Klassifizierung basieren auf *MobileNetV3-small*.
- Für die manuelle Klassifizierung der Zettel ist eine graphische Benutzeroberfläche mit dem *NiceGUI*-Framework entwickelt worden.
- Die Datenbank selber verwendet SQL v3.45.1.

Die Datenbank

 Primary Key

 Foreign Key

classes

Attribut	Typ	Beschreibung
name 	VARCHAR	Name der Klasse
trace	VARCHAR	Erkennungsmerkmal auf Zetteln
groups	VARCHAR	Zugehörigkeit zu Gruppen
sigle 	VARCHAR	→ quellen.sigle
description	VARCHAR	Eine nähere Beschreibung der Klasse
landschaft 	VARCHAR	→ landschaft.abbreviation
kreis 	VARCHAR	→ kreis.abbreviation
ort 	VARCHAR	→ ort.abbreviation

Anmerkungen

Klassen werden durch ihre Namen (name) identifiziert. In der Regel erfolgte die Benennung der Klassen folgendem Muster:

- Wortschatzsammlungen, die klar einer Gewährsperson zurechenbar sind, erhalten den Namen ebendieser Gewährsperson als Klassennamen. Ist kein Name bekannt oder handelt es sich um eine sehr kleine Sammlung, wird eine Klasse ANON_XXX_XX angesetzt, wobei XXX_XX für das entsprechende dreistellige Kreis- und zweistellige Ortskürzel steht.
- Die großen Lautschriftsammlungen erhalten den entsprechenden, voll ausgeschriebenen Ortsnamen als Klassennamen. Für kleinere Sammlungen wird analog zu oben eine Klasse LAUT_XXX_XX angesetzt.
- Sammlungen von Werksauszügen (Exzerpten) erhalten entweder den Namen des Autors oder eine der Sigle ähnliche Abkürzung als Namen.
- Die Namen aller übrigen Klassen orientieren sich an den Markierungen, die auf den Zetteln dieser Klasse zu finden sind.

Alle anderen Felder werden nur ausgefüllt, wenn es einen zutreffenden Wert gibt, d.h. sie dürfen auch NULL sein.

Die Erkennungsmerkmale (trace) einer Klasse sind die für diese Klasse typischen Kennzeichnungen, d.h. die physischen Markierungen auf den Zetteln, die zu dieser Klasse gehören. Oft handelt es sich hierbei um Stempel oder um handschriftlich notierte Namen und Orte. Gibt es für eine

Klasse mehrere solcher Erkennungsmerkmale, werden sie mit einem senkrechten Strich (|) und ohne weitere Leerzeichen aneinandergereiht: Frageb|Frgb|

Unter Gruppen (groups) werden größere Oberkategorien verstanden. Alle lautschriftlichen Klassen beispielsweise werden der Gruppe Lautschrift zugeordnet und die Wortschatzsammlungen der Gruppe Wortschatz .

Im Sinne der Erweiterbarkeit enthält die Tabelle eine vollständige Liste aller möglichen Klassen, auch wenn bisher kein Beispiel aus dieser Klasse gefunden worden ist.

classifications

Attribut	Typ	Beschreibung
zettel_id 	VARCHAR	→ zettel.id
classifier 	VARCHAR	→ classifiers.id
label 	VARCHAR	→ classes.name
confidence	FLOAT	Ein Wert zwischen 0 und 1, der die Vertrauenswürdigkeit der Klassifizierung bemisst

Anmerkungen

Der Wertebereich der confidence ist je nach Klassifizierer unterschiedlich. Für MANUEL und OCR ist sie konstant 1. Für die neuronalen Klassifizierer entspricht die confidence der Softmax-Wahrscheinlichkeit der Vorhersage. Für jeden Zettel und jeden Klassifizierer ist maximal eine Vorhersage (nämlich die wahrscheinlichste) hinterlegt.

classifiers

Attribut	Typ	Beschreibung
name 	VARCHAR	Kennung des Klassifizierers
description	VARCHAR	Kurze Erläuterung des Klassifizierers

Anmerkungen

Es gibt vier Klassifizierer:

MANUEL Der menschliche Klassifizierer.

OCR Ein Klassifizierer, der auf textueller Grundlage (d. h. auf Basis der OCR-Ergebnisse) entschied.

MODEL_V20083 Ein neuronaler Klassifizierer, der für 50 Epochen auf 20083 Mustern aus 433 Klassen trainiert worden ist.

MODEL_V25002 Ein neuronaler Klassifizierer, der für 60 Epochen auf 25002 Mustern aus 581 Klassen trainiert worden ist.

MODEL_V25002_50 Ein neuronaler Klassifizierer, der für 50 Epochen auf 25002 Mustern aus 581 Klassen trainiert worden ist.

kreise

Attribut	Typ	Beschreibung
abbreviation 	VARCHAR	Kürzel des Kreises bzw. der kreisfreien Stadt
name	VARCHAR	Voller Name des Kreises bzw. der kreisfreien Stadt

Anmerkungen

Alle Angaben gemäß [Beiband: LANDSCHAFTEN — KREISE — ORTE](#).

landschaften

Attribut	Typ	Beschreibung
abbreviation 	VARCHAR	Kürzel der Landschaft
name	VARCHAR	Ausgeschriebener Name der Landschaft
description	VARCHAR	Beschreibung der Landschaft

Anmerkungen

Alle Angaben gemäß [Beiband: LANDSCHAFTEN — KREISE — ORTE](#).

ocr_results

Attribut	Typ	Beschreibung
scan_id  	VARCHAR	→ scans.id
feature_id 	INTEGER	ID des Begrenzungsrechtecks; je Scan fortlaufend durchnummeriert
x	INTEGER	x -Koordinate der linken oberen Ecke des Begrenzungsrechtecks in Pixel
y	INTEGER	y -Koordinate der linken oberen Ecke des Begrenzungsrechtecks in Pixel
w	INTEGER	Breite des Begrenzungsrechtecks in Pixel
h	INTEGER	Höhe des Begrenzungsrechtecks in Pixel
text	VARCHAR	Der vom OCR-Modell erkannte Text

Anmerkungen

Der erste Schritt in der OCR-Erfassung ist die Text-Detektion. Das Produkt dieses Prozesses sind die oben erwähnten Begrenzungsrechtecke: eines um jeden Schriftzug.

orte

Attribut	Typ	Beschreibung
kreis 	VARCHAR	→ kreise.abbreviation
abbreviation 	VARCHAR	Kürzel des Ortes
name	VARCHAR	Ausgeschriebener Name des Ortes

Anmerkungen

Alle Angaben gemäß Beiband: LANDSCHAFTEN — KREISE — ORTE. Wie dort beschrieben ist insbesondere für jeden Kreis noch ein generischer Ort `Xy` angesetzt worden.

scans

Attribut	Typ	Beschreibung
id 	VARCHAR	Aus Kastennummer, Zettelnummer und Kennzahl für Vorder- bzw. Rückseite zusammengesetzte Scan-ID (z. B. <code>A01-00000001_1</code>)
file_name	VARCHAR	Dateiname inklusive Dateiendung (z. B. <code>00000001_1#A01_1_01_a.jpg</code>)
directory	VARCHAR	Pfad des übergeordneten Verzeichnisses (z. B. <code>A01_a-Adel/1/01_a/</code>)

sources

Attribut	Typ	Beschreibung
sigle 	VARCHAR	Sigle der Quelle oder Schrift
description	VARCHAR	Vollständige Zitierung der Quelle oder Schrift

Anmerkungen

Alle Angaben gemäß Beiband: QUELLEN UND SCHRIFTTUM.

zettel

Attribut	Typ	Beschreibung
id 	VARCHAR	Identifizierer
recto_id 	VARCHAR	→ scans.id (Vorderseite des Zettels)
verso_id 	VARCHAR	→ scans.id (Rückseite des Zettels)
lemma	VARCHAR	Lemma des Zettels

Anmerkungen

Da die Nummerierung der Scans nicht strikt fortlaufend ist, dient als `id` eine Kombination aus der Scan-Nummer und der Kastennummer (z. B. `A01-00000001`).

Das `lemma` ist dem Dateinamen des Scans der Vorderseite entnommen. Bei 23795 dieser Vorderseitenscans ist kein Lemma im Dateinamen enthalten gewesen. Grund hierfür ist wahrscheinlich nicht die prinzipielle Abwesenheit eines Lemmas auf den Zetteln sondern ein Fehler bei der Benennung der Dateien.